

O Problema Norteador (PBL)

Este documento é entregue às equipes no **Encontro 1** e é o eixo de toda a disciplina. Cada encontro subsequente é uma etapa da resolução deste problema.

1 A situação-problema

MEMORANDO INTERNO

DIRETORIA EXECUTIVA

Nos últimos anos passamos a registrar praticamente tudo o que acontece na operação. Hoje temos uma base grande, com muitos atributos, e ninguém consegue explicar o que ela diz.

Não temos rótulo, não temos classificação prévia, não temos gabarito. Ninguém nunca marcou quem é “bom” e quem é “ruim”, quem é “de risco” e quem não é. O que temos é a base bruta.

O que precisamos saber é simples de dizer e difícil de responder: **como nossas entidades se organizam naturalmente?** Existem grupos ali dentro? Quantos? O que distingue um grupo do outro? E, principalmente: **o que devemos fazer de diferente com cada grupo?**

Há uma restrição orçamentária relevante: **conseguimos financiar uma ação diferenciada por grupo, e no máximo cinco grupos.** Se vocês nos entregarem quinze segmentos, não conseguiremos agir sobre nenhum deles.

Apresentem em 60 dias, ao conselho, em linguagem de negócio. Queremos entender **por que** confiar no que vocês encontraram.

— Diretoria

Por que este é um bom problema de PBL

CARACTERÍSTICA EXIGIDA PELO PBL

COMO APARECE AQUI

Mal-estruturado	Não há enunciado fechado, nem dado suficiente de início; a equipe precisa decidir o que buscar
Autêntico	É literalmente o pedido que chega a uma área de dados em qualquer organização
Sem resposta única	Vários algoritmos produzem segmentações diferentes e defensáveis
Exige conhecimento novo	Nenhuma técnica do curso é dispensável para uma resposta completa
Com restrição real	O limite de cinco grupos força a confrontar métrica interna com viabilidade operacional
Com público	A defesa em banca obriga à tradução técnica → negócio

2 As quatro perguntas que a equipe precisa responder ao final

01

Quantos **grupos existem** e por que esse número, e não outro?

02

O que **caracteriza cada grupo** — em linguagem de negócio, não em coordenadas de centroide?

03

Que **padrões de coocorrência** existem dentro dos dados que sustentem ou contradigam a segmentação?

04

Qual **ação diferenciada** cada grupo deve receber, e como saberemos se funcionou?

3 Os 10 temas

Cada equipe escolhe **um** tema no Encontro 1. Todos trazem bases públicas, reais e verificadas: cada URL foi aberta e cada número conferido contra a página oficial da fonte. Onde a fonte **não** declara um número, isso está dito explicitamente — nenhum valor foi preenchido de memória.

Cada tema tem uma base **principal** e, quase sempre, **alternativas** no mesmo domínio, para o caso de a equipe querer mais volume, menos atrito de I/O ou um desafio técnico diferente.

Como escolher

SE A EQUIPE QUER...	VÁ PARA O TEMA
Regras de associação com transação de verdade (sem discretizar nada)	01 ou 03
Dados mistos, para exercitar distância de Gower	02, 04, 07 ou 08
Alta dimensionalidade real, onde PCA e Kernel PCA são necessários e não decorativos	05 (COIL 2000) ou 10 (SECOM)
Dados geoespaciais, onde DBSCAN encontra sua casa natural	09
Clusterização “pura”, sem nenhum rótulo para colar	01, 05 (CC GENERAL) ou 09
Base pequena, com dendrograma legível sem truncar	07 (649 linhas) ou 08 (≈ 1.470)
Eixo temporal e sazonalidade	10 (Steel) ou 09 (Metro Interstate)
Dados brasileiros e apelo de política pública	07 (Censo Escolar)

Entidade de análise: clientes (ou notas fiscais, para a cesta) · **Perfil:** negócios, marketing, tecnologia

Somos um e-commerce de gift-ware com milhares de compradores misturando varejo e atacado, e temos verba para no máximo 5 tratamentos comerciais distintos. Como a base de clientes se organiza em termos de recência, frequência e valor, e quais produtos são comprados juntos dentro de cada grupo?

BASE	ORIGEM	ACESSO	DIMENSÕES	LICENÇA
Principal: Online Retail II	UCI, ID 502	Download direto, sem cadastro	1.067.371 linhas item-transação × 8 colunas, em duas planilhas anuais: Year 2009-2010 (525.461) e Year 2010-2011 (541.910); 5.942 clientes distintos; 01/12/2009 a 09/12/2011	CC BY 4.0
Alternativa: Groceries dataset	Kaggle (heeraldedhia); base Groceries clássica do pacote <code>arules</code> do R	Conta gratuita	38.765 linhas × 3 colunas (<code>Member_number</code> , <code>Date</code> , <code>itemDescription</code>)	GPL 2

EXERCITA BEM

Apriori

Eclat

FP-Growth

K-Means

K-Medoids

Hierárquica

DBSCAN

PCA

Por que é o tema mais completo: é o único que entrega, no mesmo arquivo, **transação nativa** para regras de associação e agregação RFM para clusterização — as duas metades da disciplina em um só problema. Usar uma planilha só já é um recorte oficial, não uma amostra improvisada, e a matriz RFM cai para a ordem de 4 mil linhas.

ARMADILHAS

- Os cabeçalhos reais do dataset 502 são `Invoice` , `Price` e **Customer ID com espaço** — todo código copiado de tutorial do antigo dataset 352 quebra.
- Notas com prefixo `c` em `Invoice` são **cancelamentos**, com `Quantity` negativo. Sem tratar, o `Monetary` fica negativo e o K-Means inventa um cluster fantasma de devoluções. Há também `Price = 0` e `StockCode` que não é produto (`POST` , `DOT` , `M` , `BANK CHARGES`).
- Customer ID** é nulo em uma fatia grande das linhas: essas linhas servem para associação (a nota existe) e **não** servem para clusterizar clientes. Usar o mesmo dataframe para as duas tarefas contamina uma delas.
- Para o Apriori, a cesta é a **nota fiscal**, não o cliente. Agrupar por **Customer ID** junta dois anos de compras em uma cesta só e infla o suporte artificialmente.
- O RFM é violentamente assimétrico. Sem `log1p` + padronização, o resultado é um cluster com 4.000 clientes e três com um cada.
- I/O:** ler um `.xlsx` de 45 MB com `openpyxl` leva minutos e consome vários GB. Converta uma vez para `.parquet` e versione o convertido.

Entidade de análise: reservas · Perfil: turismo, hotelaria, negócios, operações

Operamos um resort e um hotel urbano. Que perfis de reserva existem — e o que cada perfil exige em política de overbooking, canal de venda e antecedência?

BASE	ORIGEM	ACESSO	DIMENSÕES	LICENÇA
► Principal: Hotel Booking Demand	Kaggle (jessemostipak); artigo original: Antonio, de Almeida & Nunes (2019), <i>Data in Brief</i> 22, 41-49	Conta gratuita — ou sem cadastro pelo espelho TidyTuesday: hotels.csv	119.390 reservas × 32 colunas (contadas no arquivo, não estimadas)	CC BY 4.0

EXERCITA BEM

Gower

K-Medoids

DBSCAN

K-Means

Hierárquica

PCA

Apriori

FP-Growth

Por que entrou: é a base mista mais rica do conjunto e o único tema com apelo direto para quem vem de turismo e hotelaria.

ARMADILHAS

A base empilha **dois hotéis diferentes** no mesmo arquivo (coluna `hotel1`) — decidir se são um problema ou dois é a primeira decisão de negócio da equipe. Predominância categórica exige Gower ou encoding cuidadoso, e a coluna `is_canceled` é rótulo: reservar para avaliação.

Mídia, entretenimento e recomendação

Entidade de análise: usuários (ou filmes/faixas, após agregação) · **Perfil:** tecnologia, dados, comunicação

Temos o histórico de avaliações dos nossos assinantes e nenhuma segmentação. Que perfis de consumo existem, e quais títulos são consumidos juntos dentro de cada perfil?

BASE	ORIGEM	ACESSO	DIMENSÕES	LICENÇA
► Principal: MovieLens ml-latest-small	GroupLens Research, University of Minnesota	Download direto, sem conta (1 MB)	100.836 avaliações + 3.683 tags, de 610 usuários sobre 9.742 filmes, 29/03/1996 a 24/09/2018	Licença própria GroupLens: citação obrigatória (Harper & Konstan, 2015); proibido insinuar endosso da universidade; uso comercial exige permissão prévia
Alternativa: Spotify Tracks Dataset	Kaggle (maharshipandya)	Conta gratuita — ou sem cadastro no espelho oficial do mesmo autor no Hugging Face	114.000 faixas × 22 colunas, 125 gêneros	Divergente entre as fontes: ODbL 1.0 no Kaggle, BSD no Hugging Face — vale discutir isso com a turma

EXERCITA BEM

Apriori

Eclat

FP-Growth

K-Means

K-Medoids

Hierárquica

DBSCAN

PCA

Spotify: GMM · Mean Shift

Por que entrou: é o **segundo tema com transação nativa**, em domínio completamente diferente do varejo. E com 610 usuários o dendrograma fica perfeitamente legível, sem truncamento.

ARMADILHAS

- **Não é uma tabela retangular.** São quatro CSVs relacionais, e montar a entidade de análise é parte do trabalho.
- A matriz usuário × item é 610 × 9.742 com cerca de **98% de zeros**. A distância euclidiana degenera nesse regime e o K-Means direto não produz nada interpretável — exige filtro (por exemplo, filmes com ≥ 50 avaliações), distância de cosseno, ou redução por SVD/PCA antes de clusterizar.
- No Apriori, suporte alto devolve apenas os *blockbusters* óbvios; suporte baixo explode combinatoriamente. Calibrar esse limiar **é** o exercício.

Entidade de análise: assinantes · Perfil: negócios, marketing, telecom, TI

Temos milhares de assinantes com pacotes de serviço diferentes e uma verba de retenção que cobre no máximo 5 ofertas. Que perfis de assinante existem, e qual oferta cabe a cada um?

BASE	ORIGEM	ACESSO	DIMENSÕES	LICENÇA
► Principal: Telco Customer Churn	Kaggle (blastchar); base de exemplo IBM Cognos Analytics	Conta gratuita	7.043 clientes × 21 colunas: 3 numéricas de fato, 1 binária inteira, 1 ID e ~16 categóricas nominais	Atenção: “Data files © Original Authors” — não é licença aberta nomeada. Uso didático é pacífico, mas registre a atribuição e evite redistribuir o arquivo
Alternativa: Iranian Churn Dataset	UCI, ID 563	Download direto, sem cadastro	3.150 assinantes × 13 atributos, 100% numéricos	CC BY 4.0

EXERCITA BEM

Gower

K-Medoids

Hierárquica

Apriori

FP-Growth

PCA

LDA

Iranian: K-Means · GMM · DBSCAN · Mean Shift · Kernel PCA

Por que entrou: é a **melhor vitrine de distância de Gower** do conjunto — 16 categóricas nominais contra 3 numéricas de verdade. A alternativa iraniana cobre o mesmo domínio de negócio em base puramente numérica, para a equipe que preferir K-Means e GMM sem lidar com dissimilaridade mista.

ARMADILHAS

- `TotalCharges` tem 11 valores em branco que fazem o `pandas` ler a coluna inteira como *string*. Sem `to_numeric(errors='coerce')`, a padronização quebra silenciosamente.
- A matriz de Gower para 7.043 registros ocupa cerca de **400 MB em float64**, e a hierárquica sobre ela trava um notebook de 8 GB. **Amostre 2.000 a 3.000 registros.**
- Como quase tudo é binário Sim/Não, a silhueta fica baixa (~0,2). Aqui o critério de sucesso é a **interpretabilidade do perfil**, não o índice — e reconhecer isso no relatório vale mais do que forçar uma métrica bonita.

Serviços financeiros, crédito e seguros

Entidade de análise: titulares de cartão, tomadores de crédito ou segurados · **Perfil:** finanças, contabilidade, atuária, economia

Temos uma carteira grande e a tratamos como se fosse homogênea. Que perfis de uso e de risco existem, e que política de limite, cobrança ou cross-sell cabe a cada um?

BASE	ORIGEM	ACESSO	DIMENSÕES	LICENÇA
► Principal: Credit Card Dataset for Clustering (<code>CC GENERAL.csv</code>)	Kaggle (arjunbhasin2013)	Conta gratuita	≈ 9.000 titulares × 18 colunas (1 ID + 17 numéricas de comportamento). A fonte declara literalmente “ <i>about 9000 active credit card holders</i> ” — o valor 8.950, muito citado em tutoriais, não está declarado na fonte	CC0 (domínio público)
Alternativa: Default of Credit Card Clients	UCI, ID 350	Download direto	30.000 titulares × 23 atributos + alvo. Taiwan, abr-set/2005	CC BY 4.0
Alternativa: Insurance Company Benchmark (COIL 2000)	UCI, ID 125	Download direto	5.822 clientes (<code>TICDATA2000.txt</code>) × 86 variáveis — 43 sociodemográficas por CEP + 43 de posse de produtos	CC BY 4.0
Alternativa: Medical Cost Personal (<code>insurance.csv</code>)	Kaggle (mirichoi0218)	Conta gratuita	1.338 segurados × 7 colunas, mistas	ODbL 1.0

EXERCITA BEM

K-Means

K-Medoids

Hierárquica

GMM

DBSCAN

Mean Shift

PCA

Kernel PCA (COIL 2000)

Gower

Apriori

FP-Growth

Por que entrou: o `CC GENERAL` é o problema de clusterização mais **puro** do conjunto — 17 variáveis numéricas de comportamento e **nenhum rótulo**, o que obriga a equipe a defender o k pela silhueta e pelo negócio, já que não existe acurácia para se esconder atrás. E o COIL 2000, com 86 variáveis ordinais, é a **segunda casa legítima para Kernel PCA** da disciplina.

ARMADILHAS

No `CC GENERAL` há ausentes em `CREDIT_LIMIT` e `MINIMUM_PAYMENTS`, e as variáveis monetárias têm cauda longa que exige transformação. No COIL 2000, tudo é armazenado como inteiro mas é **semanticamente ordinal** (faixas L0–L4) — tratar como contínuo é um erro conceitual que passa despercebido.

Entidade de análise: pacientes ou internações · **Perfil:** saúde, enfermagem, nutrição, gestão hospitalar

Atendemos dezenas de milhares de pessoas e oferecemos o mesmo protocolo de acompanhamento a todas. Que perfis de risco existem, e qual protocolo diferenciado cabe a cada um?

BASE	ORIGEM	ACESSO	DIMENSÕES	LICENÇA
► Principal: Cardiovascular Disease dataset (<code>cardio_train.csv</code>)	Kaggle (sulianova)	Conta gratuita	70.000 pacientes × 13 colunas (id + 11 features + alvo)	Não declarada — os metadados retornam <i>Unknown</i>
Alternativa: Diabetes 130-US Hospitals, 1999-2008	UCI, ID 296	Download direto	101.766 internações × 50 colunas, fortemente categóricas (inclui códigos ICD-9 e 23 medicamentos)	CC BY 4.0
Alternativa: Obesity Levels / hábitos alimentares	UCI, ID 544	Download direto	2.111 indivíduos (México, Peru, Colômbia) × 17 colunas, mistas	CC BY 4.0

EXERCITA BEM

DBSCAN

K-Means

GMM

PCA

Mean Shift

Hierárquica

K-Medoids

Gower

Apriori

Por que entrou: grupos genuinamente **sobrepastos** por pressão arterial e IMC — o cenário em que a atribuição probabilística do GMM ganha do K-Means de forma visível.

ARMADILHAS

- **Todas as três bases têm rótulo clínico.** Ele deve ser removido antes da modelagem e reservado apenas para avaliação a posteriori. Usá-lo na modelagem é **critério eliminatório** ([ver rubricas](#)).
- No `cardio_train`: separador é `;`, `age` está em **dias**, e `ap_hi` / `ap_lo` contêm valores fisicamente impossíveis (negativos e da ordem de milhares). Sem filtro clínico, PCA e K-Means são dominados por eles.
- Mean Shift e hierárquica são **inviáveis** em 70.000 registros (a matriz de distâncias tem 4,9 bilhões de pares). Amostre.
- No Diabetes 130: ausentes vêm codificados como `"?"`, a coluna `weight` é quase 96,9% vazia, e a mesma pessoa (`patient_nbr`) aparece em várias internações — decidir a entidade de análise é a primeira tarefa.
- No Obesity: **77% das linhas são sintéticas, geradas por SMOTE**. Isso cria estrutura de agrupamento artificial, e a equipe precisa declarar isso no relatório.

Entidade de análise: estudantes ou escolas · **Perfil:** educação, ciências humanas, gestão pública

Tratamos todos os estudantes com a mesma política de apoio. Que perfis de trajetória existem, e que intervenção pedagógica cabe a cada um? (Ou, na variante de política pública: que perfis de infraestrutura escolar existem, e onde alocar o investimento?)

BASE	ORIGEM	ACESSO	DIMENSÕES	LICENÇA
► Principal: Student Performance (<code>student-por.csv</code>)	UCI, ID 320	Download direto	649 alunos × 30 features + notas G1/G2/G3 (≈33 colunas). O ZIP traz também <code>student-mat.csv</code> , cuja contagem não é declarada na página	CC BY 4.0
Alternativa: Predict Students' Dropout and Academic Success	UCI, ID 697	Download direto	4.424 estudantes de graduação × 36 features + alvo	CC BY 4.0
Alternativa: Microdados do Censo Escolar — tabela de Escolas BR	INEP/MEC, Dados Abertos	Download direto, gratuito, sem cadastro	179.286 escolas ativas de educação básica (2024, número das Notas Estatísticas do INEP). Nº de colunas não confirmado — são centenas, e o dicionário vem dentro do próprio ZIP	Atenção: CC BY-ND 3.0 — Sem Derivações: análise à vontade, mas atenção antes de redistribuir versões modificadas dos microdados

EXERCITA BEM

Gower

K-Medoids

Hierárquica

Apriori

Eclat

FP-Growth

PCA

LDA

Censo Escolar: Apriori sobre flags binárias nativas

Por que entrou: o `student-por` é a base onde o **dendrograma fica legível sem truncar** e o Gower roda em segundos — é o tema ideal para quem quer entender a hierárquica de verdade. E o Censo Escolar é o único dado **brasileiro** do conjunto, com apelo direto de política pública.

ARMADILHAS

Predominância de categóricas e ordinais 1–5 força a discussão sobre encoding e Gower. As notas G1/G2/G3 são desempenho, não perfil: incluí-las na clusterização faz o algoritmo “descobrir” o óbvio. No **Censo Escolar**, o arquivo é `;` + *latin-1*, é preciso filtrar `TP_SITUACAO_FUNCIONAMENTO` para chegar às escolas ativas, e o volume exige recorte prévio — recomenda-se restringir a um estado e ao bloco de flags de infraestrutura.

Entidade de análise: funcionários · **Perfil:** RH, psicologia, administração, gestão

Temos uma política única de carreira e de retenção para toda a empresa. Que perfis de colaborador existem, e que trilha de desenvolvimento cabe a cada um?

BASE	ORIGEM	ACESSO	DIMENSÕES	LICENÇA
▶ Principal: IBM HR Analytics Employee Attrition & Performance	Kaggle (pavansubhasht)	Conta gratuita	35 colunas (confirmado) × ≈1.470 funcionários — atenção: o número de linhas não é declarado pela fonte ; 1.470 é o valor amplamente citado, mas não confirmado na verificação	ODbL / DbCL 1.0

EXERCITA BEM

Gower

K-Medoids

Hierárquica

DBSCAN

PCA

K-Means

GMM

Apriori

FP-Growth

Por que entrou: mistura escalas Likert, nominais e contínuas em um volume ideal para K-Medoids/PAM e para hierárquica — grande o bastante para ser real, pequeno o bastante para rodar tudo no notebook.

ARMADILHAS

É **dado sintético gerado pela IBM**, e a estrutura de grupos é artificialmente fraca — a equipe precisa saber disso antes de concluir que errou. As colunas `EmployeeCount`, `StandardHours` e `Over18` são **constantes**: se entrarem na padronização, geram variância zero e quebram o pipeline.

Entidade de análise: viagens, estações ou janelas horárias · **Perfil:** engenharia, urbanismo, dados, operações

Operamos um sistema de mobilidade e o tratamos como uniforme no espaço e no tempo. Que padrões de uso existem, e que ajuste de operação cabe a cada um?

BASE	ORIGEM	ACESSO	DIMENSÕES	LICENÇA
► Principal: Citi Bike System Data — recorte Jersey City (JC-AAAAMM-citibike-tripdata)	NYC Bike Share / Lyft	Download direto, sem cadastro, pelo índice oficial do bucket S3	13 colunas (<code>ride_id</code> , <code>rideable_type</code> , <code>started_at</code> , <code>ended_at</code> , estações de origem/destino, <code>start_lat</code> , <code>start_lng</code> , <code>end_lat</code> , <code>end_lng</code> , <code>member_casual</code>). Contagem de linhas não verificada — o que se confirmou foi o tamanho dos arquivos mensais (2,7 a 3,7 MB compactados)	NYCBS Data Use Policy — uso não comercial com atribuição; não é Creative Commons , leia os termos antes de redistribuir
Alternativa: Metro Interstate Traffic Volume	UCI, ID 492	Download direto	48.204 horas de observação × 9 colunas (tráfego + meteorologia), rodovia I-94, Minnesota	CC BY 4.0

EXERCITA BEM

DBSCAN

Mean Shift

Hierárquica

K-Means

K-Medoids

GMM

PCA

Apriori

Eclat

FP-Growth

Por que entrou: é o **único tema geoespacial** do conjunto. Sem ele, DBSCAN e Mean Shift ficam órfãos do seu caso de uso natural, e os pontos de ruído deixam de ser um produto para virar apenas um resíduo.

ARMADILHAS

- Use `metric='haversine'` com as coordenadas **em radianos**, e `eps` em metros dividido por 6.371.000.
- Risco conceitual central:** como as viagens partem de estações fixas, um DBSCAN sobre `lat` / `lon` puros apenas “redescobre” as estações — resultado trivial e sem valor. Force o espaço de atributos a incluir **hora do dia, duração e tipo de usuário**.
- O padrão de nomes dos arquivos no S3 não é uniforme (alguns sem `.csv` , um com espaço no lugar do hífen), então script de download automático falha sem tratamento.

Entidade de análise: ciclos de máquina, janelas de operação ou horas de medição · **Perfil:** engenharia, exatas, operações, meio ambiente

Nossa operação tem regimes distintos que ninguém mapeou, e comportamentos atípicos que só percebemos depois da falha. Que regimes existem, e o que é genuinamente anômalo?

BASE	ORIGEM	ACESSO	DIMENSÕES	LICENÇA
► Principal: AI4I 2020 Predictive Maintenance	UCI, ID 601	Download direto (CSV, 510 KB)	10.000 ciclos × 14 colunas: 5 numéricas, 1 ordinal (<code>Type</code>), 1 ID e 6 binárias de falha	CC BY 4.0
Alternativa: SECOM	UCI, ID 179	Download direto	1.567 lotes × 591 sensores , com ausentes. O rótulo pass/fail vem em arquivo separado (<code>secom_labels.data</code>)	CC BY 4.0
Alternativa: Steel Industry Energy Consumption	UCI, ID 851	Download direto	35.040 janelas de 15 min = exatamente um ano (365 × 96) × 9 atributos + data/hora + <code>Load_Type</code>	CC BY 4.0
Alternativa: Air Quality	UCI, ID 360	Download direto	9.358 horas de medição × 15 colunas (5 sensores químicos + 5 concentrações de referência + meteorologia)	CC BY 4.0, com ressalva literal: “exclusively for research purposes. Commercial purposes are fully excluded”

EXERCITA BEM

Todos. É o tema com maior cobertura algorítmica:

K-Means K-Medoids Hierárquica DBSCAN Mean Shift GMM **PCA e Kernel PCA (SECOM)**
Gower LDA Apriori FP-Growth

Por que o AI4I é o principal e o SECOM é alternativa: as 591 colunas do SECOM chamam-se `Attribute 1` a `Attribute 590` — são **anônimas**. Em um PBL sobre CRISP-DM, isso inviabiliza o entendimento de negócio e a interpretação dos clusters: a equipe produz um PCA bonito e não consegue contar história nenhuma. O SECOM continua ofertado — é onde Kernel PCA realmente ganha sentido — mas só para equipe que aceite conscientemente esse custo.

ARMADILHAS

- **AI4I:** os dados **contradizem a descrição oficial da página do UCI** (a distribuição real de `Type` e as contagens de modos de falha não batem com o texto). Isso é excelente como exercício de checagem — e péssimo se a equipe citar a página como verdade no relatório sem conferir.

- **Steel:** `Load_Type` é quase uma função determinística de `Usage_kWh`. Se entrar como atributo, o cluster “descoberto” é o próprio rótulo. Use apenas para validação externa.
- **Air Quality:** os ausentes vêm codificados como **-200**. Sem tratar, destroem qualquer padronização e qualquer PCA.

TEMA ABERTO

Contexto próprio *(recomendado quando possível)*

Entidade de análise: definida pela equipe.

A equipe traz uma base do próprio ambiente de trabalho. Requisitos mínimos: ao menos **800 registros** e **8 atributos**, sendo pelo menos 4 numéricos. Dados sensíveis devem ser anonimizados **antes** de entrar no repositório, e a equipe deve declarar, no Canvas, a base legal e as restrições de uso.

É a escolha mais valiosa quando disponível: a fase de entendimento de negócio deixa de ser simulação, e o resultado tem chance real de ser implantado.

4 Canvas do Problema

Preenchido no Encontro 1 e revisado a cada encontro. É o artefato de rastreabilidade entre o pedido da diretoria e o que a equipe efetivamente fez.

EQUIPE:	TRILHA:
1 · CONTEXTO DE NEGÓCIO Que organização é essa, o que faz, quem decide o quê?	2 · A DOR O que dói hoje por não existir essa segmentação? Quem sofre com isso?
3 · OBJETIVO DE NEGÓCIO O que a organização quer realizar (não a técnica)	4 · CRITÉRIO DE SUCESSO DO NEGÓCIO Como a diretoria vai saber que deu certo? Métrica e meta.
5 · META DE MINERAÇÃO O resultado técnico esperado: agrupamento? associação? redução de dimensionalidade?	6 · CRITÉRIO DE SUCESSO TÉCNICO Silhueta mínima aceitável, nº máximo de grupos, % máximo de ruído...
7 · ENTIDADE DE ANÁLISE O que é uma “linha” da base?	8 · FONTE E VOLUME DOS DADOS Origem, período, nº de registros e de atributos, permissões de uso
9 · PERGUNTAS ORIENTADAS A DADOS 3 a 5 perguntas SMART	10 · RESTRIÇÕES E RISCOS Orçamento, prazo, legais, éticos, qualidade dos dados
11 · AÇÃO ESPERADA POR GRUPO Que tipo de decisão será tomada com o resultado? (se a resposta for “nenhuma”, o projeto não deveria existir)	

Perguntas orientadas a dados: o padrão SMART

Toda pergunta do campo 9 precisa ser **específica**, **mensurável**, **alcançável** com os dados disponíveis, **relevante** para a decisão e com **prazo** definido.

“Quem são nossos melhores clientes?”	“Entre os clientes com pelo menos 3 compras no período de 12/2010 a 12/2011, quantos grupos distintos emergem quando consideramos recência, frequência e valor monetário, e qual grupo concentra mais de 40% da receita?”
“Existe algum padrão nos dados?”	“Quais combinações de até 3 produtos ocorrem juntas com suporte $\geq 1\%$ e lift $\geq 1,5$ nas transações do último trimestre?”
“Os equipamentos estão bem?”	“Que percentual dos ciclos de operação de 2020 é classificado como ruído por um DBSCAN calibrado com $\text{minPts} = 2 \times d$, e qual a taxa de falha registrada nesses ciclos?”

5 O Quadro PBL

Preenchido em papel A1 ou quadro branco no início de cada encontro e fotografado para o repositório (`docs/pb1/`). É a evidência do raciocínio da equipe.

FATOS	HIPÓTESES	QUESTÕES DE APRENDIZAGEM	PLANO DE AÇÃO
O que sabemos com certeza sobre o problema e sobre os dados	O que suspeitamos que seja verdade, e ainda não verificamos	O que precisamos aprender para testar as hipóteses	O que faremos, quem faz e até quando

Regra do quadro: uma hipótese só sai da coluna 2 quando houver evidência nos dados que a confirme (vira Fato) ou que a refute (vira nota de rodapé no relatório). Hipóteses derrubadas **não são apagadas** — são parte do resultado.

6 Produto final esperado

Ao final do Encontro 5, cada equipe entrega:

01 Repositório versionado (fork do `project-template`) com notebooks executáveis de ponta a ponta, dados em `data/` , figuras em `reports/figures/` e histórico de commits.

02 Relatório analítico em `reports/` , estruturado em:

Cap. I — Contexto e Canvas do Problema

Cap. II — Perguntas orientadas a dados

Cap. III — Análise exploratória (as 8 fases) e coleção de insights

Cap. IV — Preparação dos dados e decisões tomadas

Cap. V — Modelagem: algoritmos testados, parâmetros e comparativo

Cap. VI — Avaliação: métricas internas e leitura de negócio

Cap. VII — Personas dos grupos e ações recomendadas

Cap. VIII — Plano de implantação e monitoramento

Cap. IX — Limitações, hipóteses derrubadas e próximos passos

- 03 Pitch executivo** de 10 minutos, sem jargão, com a resposta às quatro perguntas da seção 2.
- 04 Registro do percurso PBL:** fotos dos cinco quadros e a autoavaliação de cada integrante.